지워진 코드 검색엔진

Deleted Code Search

오픈소스에서 지워진 코드 - 왜 지웠고, 대신 무엇이 들어갔나

팀 깻잎 · 홍성제 32225001 · 안재헌 32222550 · 최희수 32224818

단국대학교 소프트웨어학과 · 담당교수 박규식

GitHub

1. 작품 개요

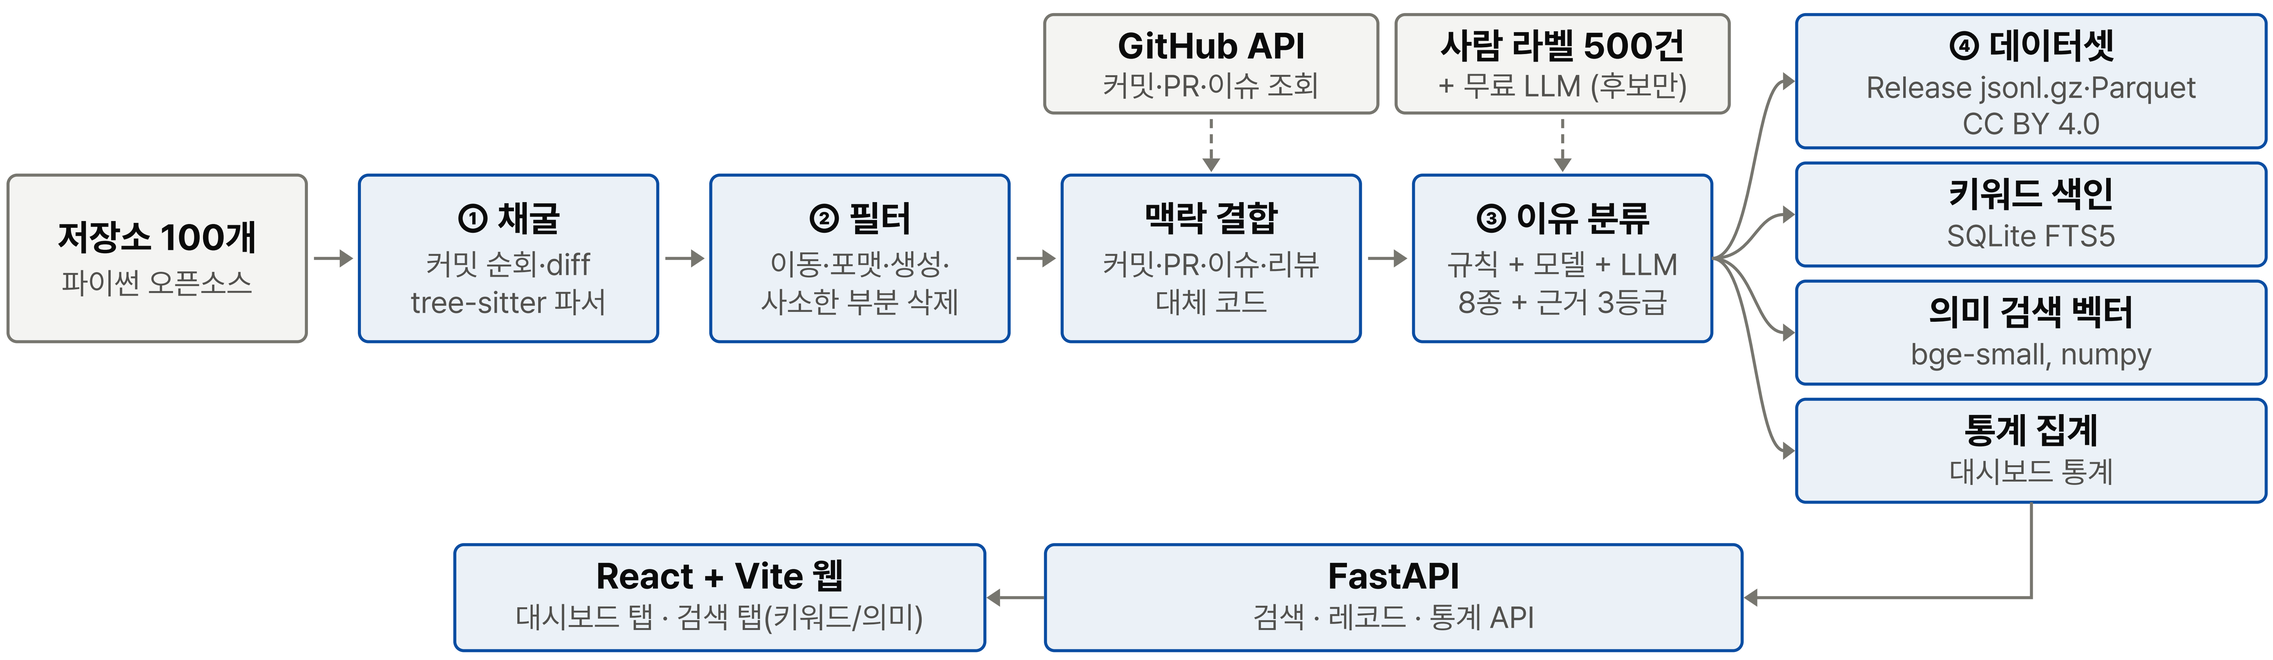
문제

개발 지식의 상당 부분은 "무엇을 하지 말아야 하나"인데, 그 지식은 어디에도 저장되지 않는다. 지운 코드는 깃 이력에 남지만, "왜 지웠는지"는 커밋 메시지·PR·이슈·리뷰에 흩어져 있어 찾기 어렵다. 코드 검색은 지금 있는 코드만 색인하고, AI 코딩 도구는 살아남은 코드로 학습했다.

우리 답

오픈소스 저장소 100개에서 삭제된 함수를 뽑고, 삭제 이유와 대체 코드를 묶어 검색할 수 있게 만든다. 분류한 레코드마다 근거 등급을 달아 이유가 얼마나 확실한지 함께 보여 준다.

2. 개발 세부 내용



이유 8종

BUG	버그 수정	**DEAD**	죽은 코드
PERF	성능	**DESIGN**	설계 변경
SEC	보안	**FEAT**	기능 제거
LIB	라이브러리 교체	**UNK**	불명

근거 3등급

EXPLICIT	PR·이슈·커밋에 이유가 문장으로 있음
INFERRED	닫힌 목록 6종의 구조적 신호로 추론
UNKNOWN	판단 불가

기술 스택 Python · tree-sitter · scikit-learn + LLM · SQLite FTS5 · fastembed + numpy · FastAPI · React

3. 구현 결과

100 **파이썬 저장소** 기본 브랜치 커밋 순회	**5,383,893** **삭제된 함수** tree-sitter 함수 경계	**1,354,052** **의미 있는 삭제** 노이즈 제거 후 남은 삭제	**723,087** **함수 전체 삭제** 의미 검색 대상
73.0% **이유 분류 (8종)** 4묶음 85.0% 기준선 B 38.0%	**0.625** **의미 검색 P@10** 키워드 0.325의 약 2배	**50ms** **의미 검색 응답 p95** 72만 건 전수 내적	**500건** **사람 확정 라벨** dataset-v0.9 CC BY 4.0 공개



상세 패널 지워진 코드·커밋·PR·이슈·대체 코드·이유·근거 문장을 한곳에서 본다

4. 기대효과

개발자

같은 방식을 썼다가 지운 프로젝트의 코드와 이유, 대체 코드를 찾아 같은 실수를 피한다

연구

삭제 이유 분포 데이터로 분석·논문
함수 단위 삭제 + 이유 + 대체 코드 데이터셋, 사람 확정 라벨 500건

차별점

"삭제 함수 + 이유 + 대체 코드" 데이터셋과 크로스 저장소 삭제 코드 의미 검색은 선행 조사에서 찾지 못했다

확장 순서

- 코드 진단 API
- VS Code 플러그인
- 개인 저장소 이유 추정
- 두 번째 언어